

使用 MEMS 感測器實現以 IoT 為基礎的預測性維護

D0748284 楊孟軒

1 Introduction

1.1 Motivation

隨著工業機械能夠完成越來越複雜化、自動化的任務，這樣的發展意味著機械各部件得承受更為複雜的運作模式，也就是說，在該作業環境可能易遭受高溫高壓和高運轉量的困擾。因此，故障是不可避免的問題。由於機械設備故障容易導致經濟及能源消耗的損失，故機械狀態監控的需求變得日趨重要。

簡單來說：~~大專生計劃錢都拿了現在逃不掉了~~ 嗚嗚

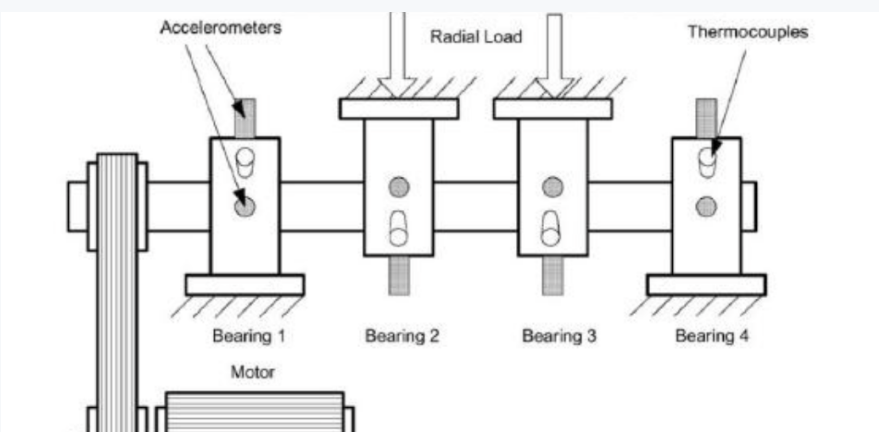
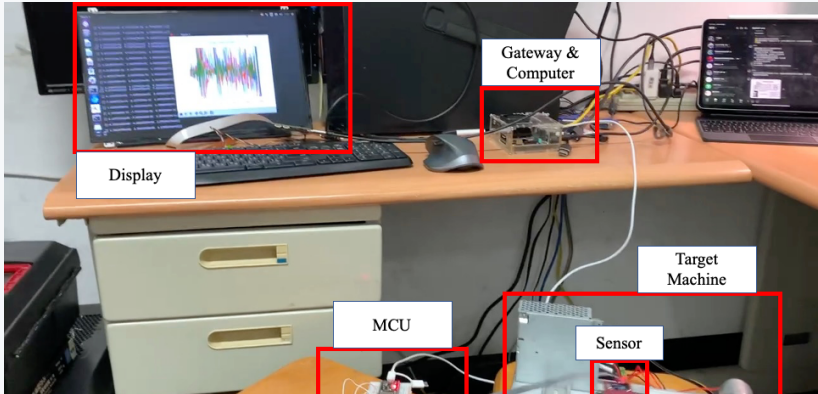
1.2 Task Definition

1. 利用遷入式設備搜集工具機運作數據
2. 輕量化模型並直接在遷入式設備部署
3. 考慮到多個axis交互關係分析軸承運作狀態

2 Dataset description

1. IMS dataset(aka NASA Bearing Dataset)
2. 實際設備搜集資料

2.1 Dataset description

	IMS	實際設備搜集資料
Channels	4	3
Number of files	$\approx 20M$	$\geq 20k$
Window size(frequence)	10240	4096
setup		

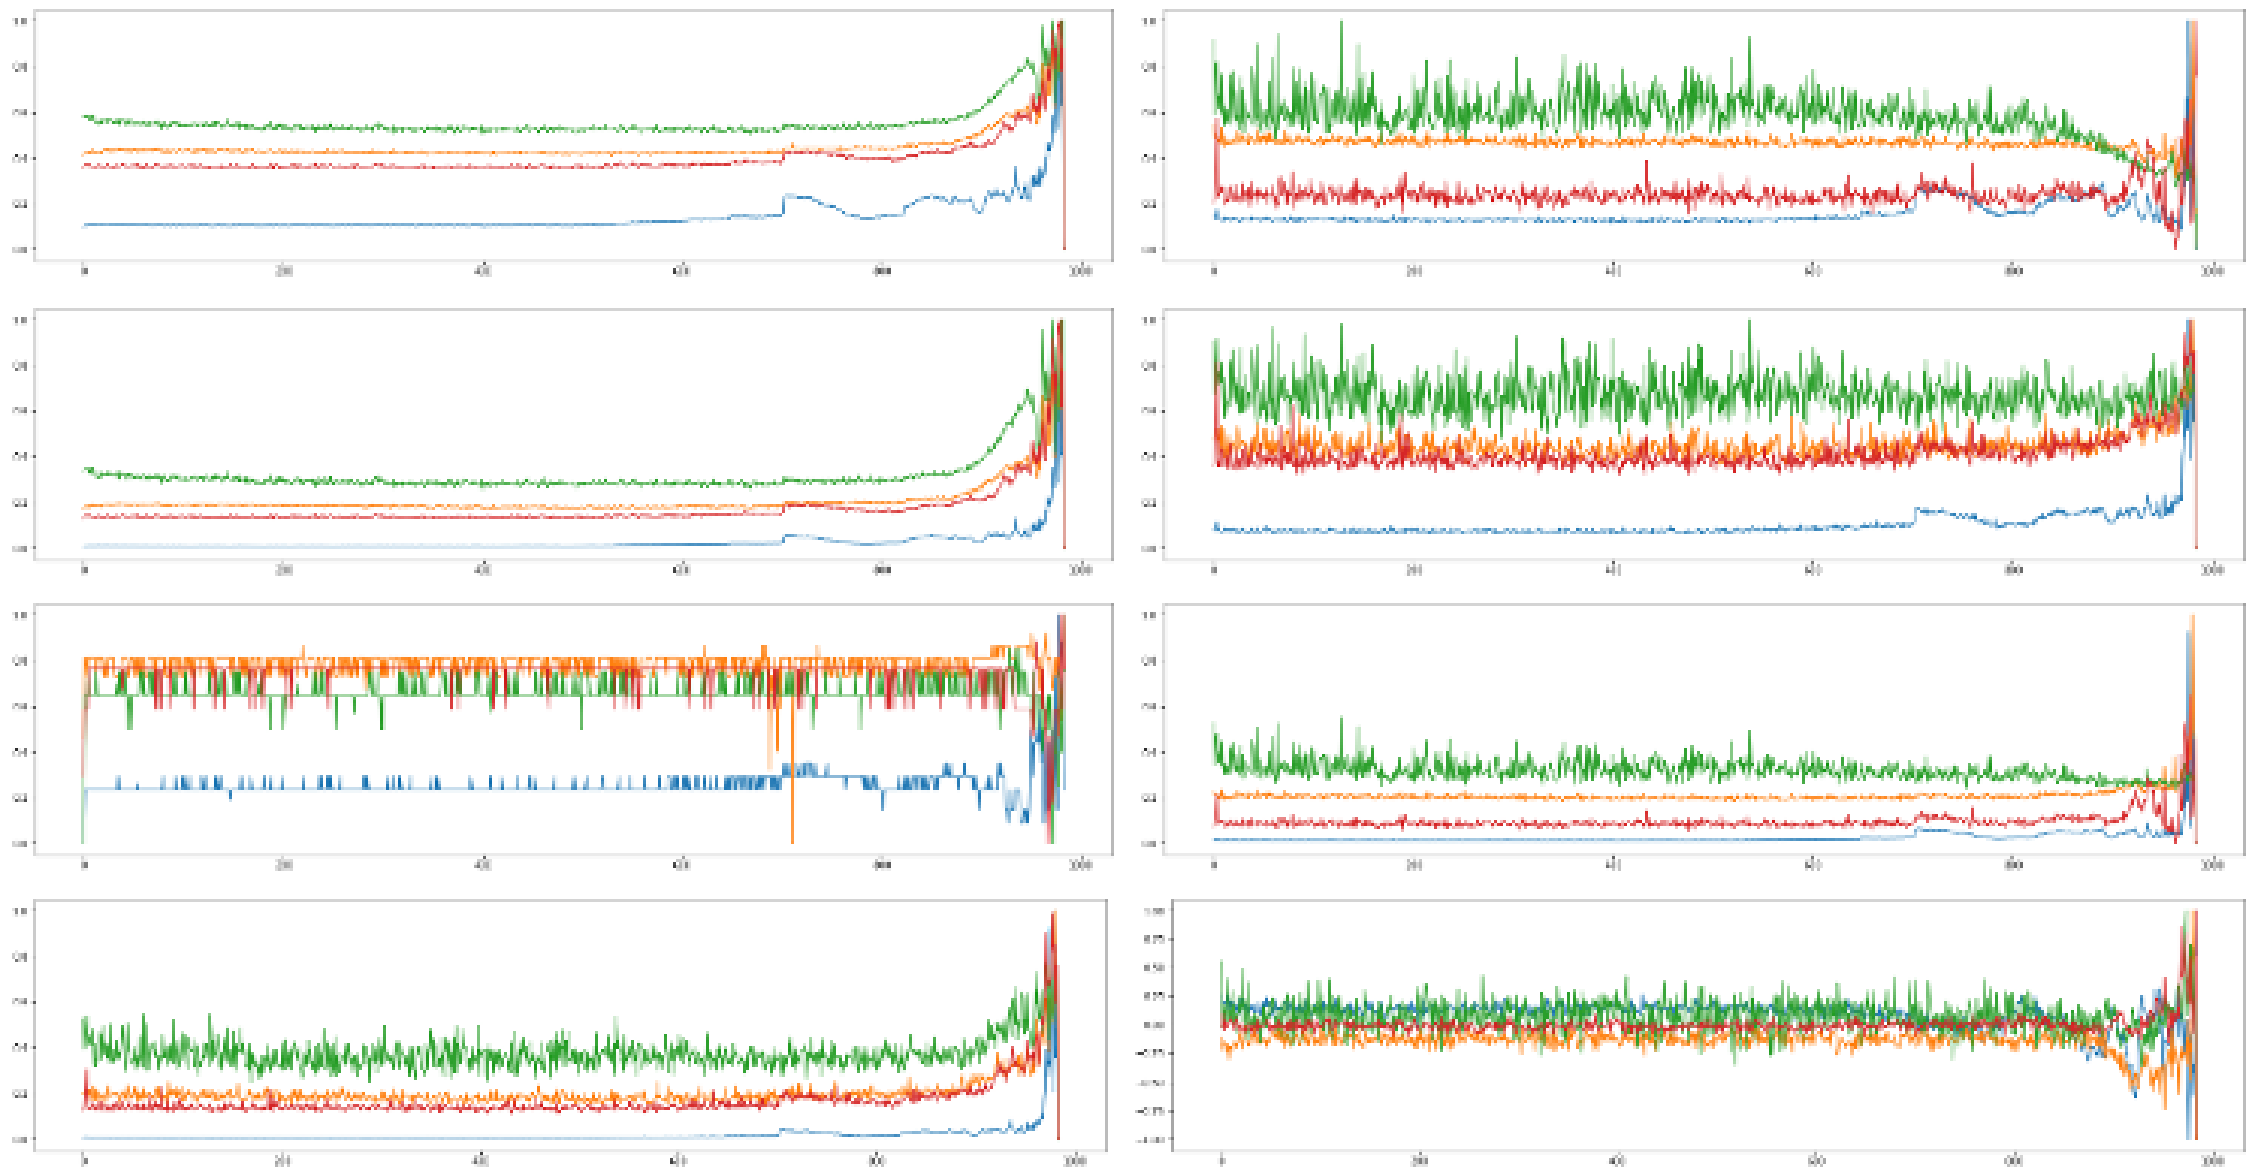
3 Learning techniques

3.1 feature extraction

將震動數據依照 *window size* 分開

並分別計算個別的時域特徵(*timedomain features*)

- $\text{RMS} = \sqrt{\left(\frac{1}{N}\right) \sum_{i=1}^N (x)^2}$
- $\text{VAR} = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$
- $\text{KUR} = \frac{1}{N} \sum_{i=1}^N \frac{(x_i - \bar{x})^4}{\sigma^4}$
- $\text{PeakValue} = \text{max value} - \text{min value}$
- $\text{SKW} = \frac{1}{N} \sum_{i=1}^N \frac{(x_i - \bar{x})^3}{\sigma^3}$
- $\text{MED} = \left(\frac{N+1}{2}\right)^{th}$



- Normalized features used as training data

3.2 Classifiers model

分別用以下幾種演算法對資料進行訓練，比較輸出結果並考量實際效率以進行部署

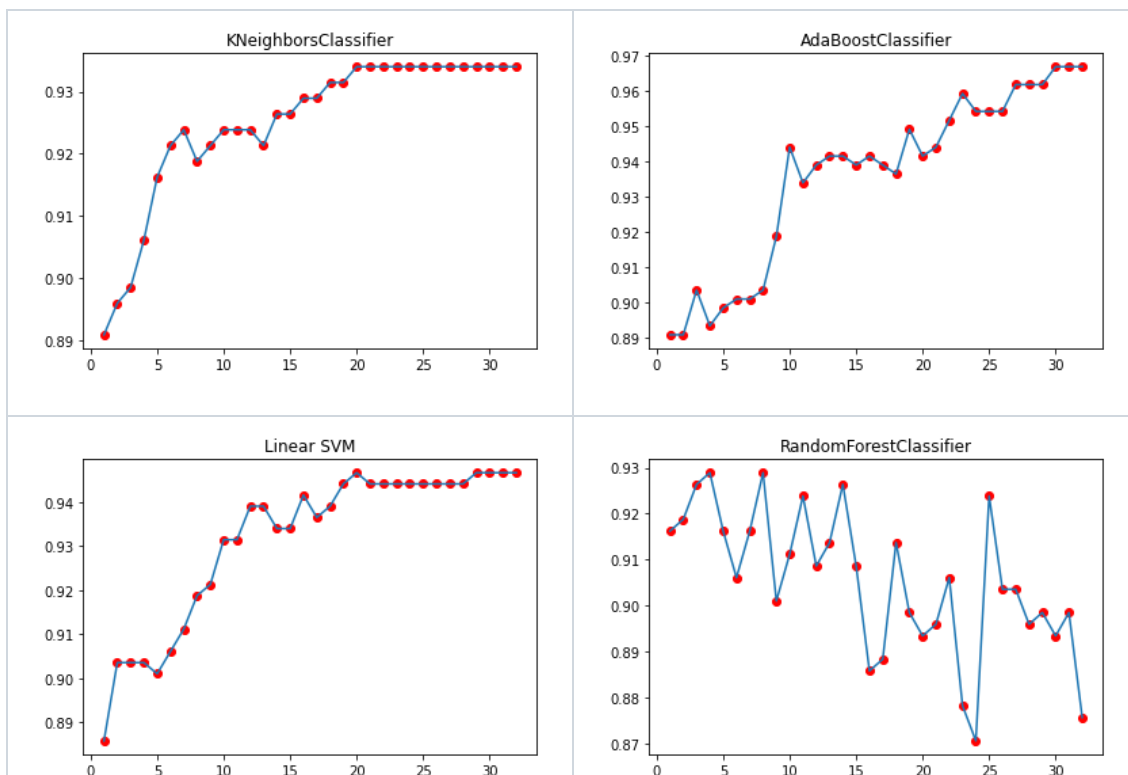
1. Nearest Neighbors
2. Linear SVM
3. RBF SVM
4. Decision Tree
5. Random Forest
6. AdaBoost
7. Naive Bayes

4 Result and disscussion

4.1 Classification Results Obtained Without PCA


model	Accuracy(%)	Parameter
Nearest Neighbors	93.4	N=3
Linear SVM	83.2	kernel="linear", C=0.025
RBF SVM	93.4	gamma=2, C=1
Decision Tree	97.9	max_depth=5
Random Forest	94.7	max_depth=5
AdaBoost	98.4	
Naive Bayes	87.5	

4.2 Classification Results Obtained using PCA



- 我們選擇了上表最佳的兩個模型(AdaBoost, Decision Tree)和最低的(Linear SVM)額外加KNN，比較PCA對特徵降維對準確性的影響


4.3 Deploy model in MCUs



5 Conclusion

5.1 Conclusion

要把模型用到MCU會需要比較多的步驟，因此這次在實際部署在MCU上目前只有使用PCA+KNN測試，同時我們也嘗試定義其他工具機的狀態標籤，但因為感應器的限制，當工具機高功率運作加速度會大於最大採樣值，因此本次以三個狀態作為標記。



5.2 未來展望

這次研究在實際部署中，遇到最大的問題是要在兼顧模型正確性的同時顧慮到MCU的計算量，因此希望未來可以用兩段式的架構，先藉由前端MCU搜集數據後傳送到伺服器分析，以使用更複雜的模型進行處理

6 References

- [1] Analysis of NASA Bearing Dataset of the University of Cincinnati by Means of Hjorth's Parameters
- [2] Analysis of the Rolling Element Bearing data set of the Center for Intelligent Maintenance Systems of the University of Cincinnati
- [3] A. Widodo, E. Y. Kim, J. D. Son, B. S. Yang, A. C. Tan, D. S. Gu, ... and J. Mathew, "Fault diagnosis of low speed bearing based on relevance vector machine and support vector machine," Expert systems with applications, vol. 36 no. 3, pp. 7252-7261, 2009.