

機器學習於感應馬達複合故障診斷

Multi-Fault Diagnosis in Induction Motor Using Machine Learning Algorithms

林旻頌¹
Min-Chieh Lin

賴家晨¹
Chia-Chen Lai

徐士賢^{1,*}
Shis-Hsien Hsu

李建興²
Chien-Hsing Lee

¹ 逢甲大學電機工程學系
Department of Electrical Engineering, Feng-Chia University
j0011504@gmail.com abc311453@gmail.com * shihhsu@fcu.edu.tw

² 成功大學系統及船舶機電工程系
Department of Systems and Naval Mechatronic Engineering, National Cheng Kung University
chienlee@mail.ncku.edu.tw

摘要

馬達具有良好操作性、適應性與維護簡單的優點，廣為工業與民生使用之旋轉設備，在長時間的運作下，其各部位的磨損亦會肇生電氣或機械故障，如軸承偏心或線圈短路等問題。雖然定期的保養可早期發現異常馬達，但畢竟非即時又耗費人力與成本。本研究以機器學習方法實現馬達故障即時檢測與診斷，提高使用妥善率。於馬達裝設感測器量測取得其電氣與機械振動頻譜資訊，透過機器學習之 K-近鄰演算法於時域進行綜合故障分析與判斷種類，簡單、即時與正確的監測馬達故障。

關鍵詞：馬達故障診斷、機器學習、K-近鄰演算法

Abstract

Induction motors are widely employed in the industry and household fields and have advantages of good performance in operability, adaptability, and maintenance. However, the electrical and mechanical failures may occur due to the long-term working such as bearing eccentricity and stator interterm short circuit. Early detection of abnormal conditions in induction motors can be achieved through regular maintenance but it is not instantaneous and need more costs. This paper presents multi-fault diagnosis in induction motors using K-Nearest Neighbor (KNN) machine learning algorithms and performs comprehensive analysis and fault diagnosis in the time domain.

Keywords: motor, fault diagnosis, KNN, machine learning

I. 簡介

在工業發達的社會，馬達所帶來的效率與實用性是十分可觀的，因此各種領域對於馬達的應用也與日俱增。由於馬達的運轉往往需要承受來自不同方面的應力，因此容易發生故障，若馬達發生故障且未即時發現及維修輕則導致效能降低，重則可能產生機械損毀甚至人員傷亡。因此為了避免馬達發生不可逆的故障，即時監控馬達的健康狀態在近期成為了不可或缺的技术。

在許多文獻中都已經提出基於電流、電壓、溫度和振動來進行馬達的健康監控[1]，馬達故障可大致分為機械與電氣(器)故障兩大類，機械部分常見的是轉子與軸承故障，其中轉子故障又分為轉子不平衡、轉子彎曲、轉子不對中以及轉子鬆動，而軸承故障則分為內環損傷、

外環損傷及滾珠損傷等。而電氣部分則是有定子、轉子間氣隙不均、轉子斷條、繞組短路以及三相電壓相位不平衡或欠相等問題。在馬達診斷的方法中，常使用的方法有定子電流檢測法、軸心軌跡分析法和振動檢測法等。由於相關文獻都為單一性故障診斷，本文將透過使用 ML-KNN 演算法對多種馬達故障之感測訊號進行分析進而有效快速判斷故障種類。

II. 資料分析與診斷

2.1 馬達故障訊號感測與分類

隨著工業 4.0、監控和數據採集(Supervisory Control And Data Acquisition, SCADA)與物聯網技術的開發，馬達故障檢測的方法已經從透過維修保養才被發現，進步到以感測器即時監測與警示。機械部分最常用的檢測方法是經由振動規感測馬達的振動情形進行資料蒐集，因其發展較其他檢測法更加成熟完備，也是現今工業界中最常使用的檢測法，根據 ISO2372，對於各類旋轉機械之振動限制已有清楚的規範。在分辨馬達故障的部分，已有大量文獻將故障的種類與其故障發生時所產生的頻譜被歸類出來[2-3]。此外，在電氣故障的部分則有定子繞阻短路、轉子間氣隙不均、轉子斷條等問題。常用的檢測方法為定子電流檢測法，藉由量測定子之三相電流，當故障時電流頻譜會產生與之對應的故障特徵[4-6]。

2.2 機器學習方法與資料庫選定

1956 年在達特茅斯學院舉行的一次會議上正式確立了人工智慧，至今超過了 50 餘年，但近年來由於硬體設備的提升且運算量大幅度的增加，人工智慧再次產生新的風潮，也廣泛的被應用在馬達故障診斷[7]。機器學習有很多種類，較常出現的大多透過資料是否有標籤(Label)來做分類，可分為監督式(Supervised)、非監督式(Unsupervised)與增強式(Reinforcement)等三類。而監督式學習是電腦從標籤化(Labeled)的資訊中分析模式後做出預測的學習方式，標記過的資料就好比標準答案，電腦在學習的過程透過對比誤差，一邊修正來達到更精準預測，這樣監督式的學習有準確率高的優點。

資料透過程式採集、過濾後取得較精確的特徵，判斷時透過大量的計算，找出最佳的分類依據，最後透過不斷的驗證配合理論的探討，則可以獲得馬達故障分類，甚至預測可以預測馬達未來的狀態。數據收集與分析方面是聚焦在馬達故障分析與預警，也就是工業 4.0 的智慧檢測，進行馬達運轉的異常檢測，針對所收集之資訊

進行數據挖掘。數據挖掘方法大概分為統計法(迴歸分析、判別分析、聚類分析、探索性分析)、機器學習法(決策樹、規則歸納、範例學習、遺傳算法)、神經網路法(前向神經網路、自組織神經網路)以及數據庫法(多維數據分析或線上分析處理)。

本研究採用監督式學習,利用感測元件收集馬達之時域或頻域的訊號來比較分析,用以判斷故障種類並提出預警訊息;在資料量的部分,為提高資料的特徵數目,吾人設定不同之馬達故障情境並搭配轉速訊號進行合併判斷,用以加強分類器的訓練模型,同時也能提升訓練結果的準確度。在分類器的選擇上,由於資料分布並非線性趨向,而排除傳統的線性迴歸,但比較了幾種非線性的分類器,如羅吉斯迴歸(Logistic Regression)、決策樹以及 K-近鄰演算法(K-Nearest Neighbor, KNN) [8]。羅吉斯迴歸類似於一般的線性迴歸,由於其曲線為非線性,在分類上有不錯的效果,但主要為二元的分類器,不太符合本研究多故障類型的分類使用。決策樹方法跟前面的差別是它擁有對資料的極高配適度,可以找到重要的特徵值並以此作為分類依據,然在資料量過少或特徵值過低時,便無法有效的分析。但因在馬達故障上,多數的資料並沒有太大差距,此方法也並未選用。故本研究採用 K-近鄰演算法來進行故障分類,其優點是可自行修正所採樣的數量,且依據資料量的大小再做調適,並可在低量資料時也能有效的分類出來。

藉由前述資料蒐集與分類存放於資料庫,將可得到大於 10 種的特徵值,為避免運算量的大幅提高與增加資料的可視化程度,本研究採用資料處理上常見的主成份分析(Principal Component Analysis, PCA)[9],利用正交轉換對大量的變數資料做線性轉換,對原始數據進行相對縮放。先處理完 PCA 後,再使用 K-近鄰演算法進行數據的分類,其利用特徵空間計算每筆資料相對的密度值,通常用於分類器或迴歸分析。因此,本研究利用其密度的特性,將密度過低的資料視為雜訊並將其過濾,透過上述的資料處理,再將整理後的資料匯入分類器中,可以成功訓練分類器。由於資料的乾淨程度增加,故測試結果可以到 99%以上甚至到完全吻合。

由於本研究需要蒐集大量的數據來進行判斷,在資料儲存這塊也是一個重要的議題。資料庫部分,經過比較多種資料庫後,選擇了 MySQL 資料庫,其系統相容性高,且擁有更優的工作環境及效能,尤其是多執行緒這方面提供資料採集時的便利性,綜合比較後最符合本研究需求,表 1 為 MySQL 與其他資料庫之比較。

表 1：不同資料庫特性比較表

項目/資料庫	MySQL [10]	PostgreSQL	Microsoft SQL
系統相容	極高	普通	低(C)
學習成本	普通	高	低
安全性	中	高	高
系統價格	免費	高	高
多執行緒	強	無	無
使用趨向	開發測試	商業應用	財經資料

III. 馬達故障頻譜特徵

馬達故障類別常見的為機械與電氣(器)故障兩大類。以下為介紹各種馬達故障時,所產生的特徵頻譜[3-4][11-13]。根據本研究調查,馬達故障原因大部分為電壓欠相、定子繞組故障、轉子故障與軸承故障等問題。轉子故障的特徵振動頻譜主要由馬達的轉速頻率及其他諧波頻率所形成,圖 1 至圖 9 為模擬馬達於不同狀態下進行資料採集後,利用快速傅立葉(Fast Fourier Transform, FFT)轉換後,所繪之特徵頻譜圖,做為本研究演算法之結果驗證參照。

圖 1 為發生轉子不平衡時所產生之特徵頻譜圖,其特徵頻率為 1 倍轉速頻率,以 $1f$ 表示之。圖 2 為轉子彎曲之特徵頻譜圖,在 $1f$ 、 $2f$ 和 $3f$ 出現特徵頻譜,其中以 $1f$ 為最大值,而 $2f$ 及 $3f$ 則是隨著頻率增加而下降。圖 3 為轉子不對中的特徵頻譜圖,在 $2f$ 出現最大值,伴隨著 $1f$ 、 $3f$ 、 $4f$ 等倍頻,其中 $1f$ 和 $3f$ 約略相等且低於 $2f$,而 $4f$ 則低於 $1f$ 和 $3f$ 。圖 4 則是發生轉子鬆動時所產生的特徵頻譜圖,在 $1f$ 、 $2f$ 及 $3f$ 產生特徵頻譜,且隨著頻率增加而下降,在 $0.5f$ 、 $1.5f$ 和 $2.5f$ 也產生較小的峰值,但隨頻率增加而下降。軸承故障的特徵頻譜主要由滾珠在軸承內所產生的不同頻率所組成,可分為內環損傷、外環損傷以及滾珠損傷。軸承由內環、外環、滾珠以及保持架(Fundamental Cage)所組成。在馬達運轉時各組件間則是會產生特有頻率,如滾珠通過內環同一點的頻率、滾珠通過外環同一點的頻率、滾珠旋轉頻率及保持架頻率。圖 5 為發生內環損傷時所產生的頻譜圖,其頻率簇由式(1)、(2)來表示。

$$mf_{in} \pm nf_{\omega} (m = 1, 2, 3 \dots; n = 0, 1, 2 \dots) \quad (1)$$

$$f_{in} = (f_{\omega}M + df_{\omega}M \cdot \cos\alpha/D)/2 \quad (2)$$

其中, f_{in} 為滾珠通過內環同一點的頻率、 f_{ω} 是轉速頻率、 M 為滾珠數目、 d 為滾珠直徑、 D 為軸承節徑、 α 為接觸角,以及 m 和 n 為常數。圖 6 為發生外環損傷所產生之頻譜圖,其頻率簇由式(3)來表示。

$$mf_{out} \pm nf_{cage} (m = 1, 2, 3 \dots; n = 0, 1, 2 \dots) \quad (3)$$

$$f_{out} = (f_{\omega}M - df_{\omega}M \cdot \cos\alpha/D)/2 \quad (4)$$

$$f_{cage} = (f_{\omega} - df_{\omega} \cdot \cos\alpha/D)/2 \quad (5)$$

其中, f_{out} 為滾珠通過外環同一點的頻率,而 f_{cage} 則是軸承保持架的頻率。圖 7 為滾珠損傷所產生的頻譜圖,其特徵頻率簇由式(6)組成。

$$mf_{roller} \pm nf_{cage} (m = 1, 2, 3 \dots; n = 0, 1, 2 \dots) \quad (6)$$

$$f_{roller} = (Df_{\omega}/d - df_{\omega} \cdot \cos^2\alpha/D)/2 \quad (7)$$

其中, f_{roller} 表示滾珠旋轉頻率。

而電氣故障共分為氣隙不均、轉子斷條和三相電壓相位不平衡等故障種類。圖 8 為氣隙不均時所產生的特徵頻譜,其頻率以 $1f$ 和 $2f_L$ 較為明顯,並分別帶有頻距為 f_p 的伴頻。其中 f_L 為電源頻率, f_p 則為極通頻率並以式(8)來表示。

$$f_p = P \cdot f_s \quad (8)$$

其中， P 為轉子極數、 f_s 為滑差頻率如式(9)來所示。

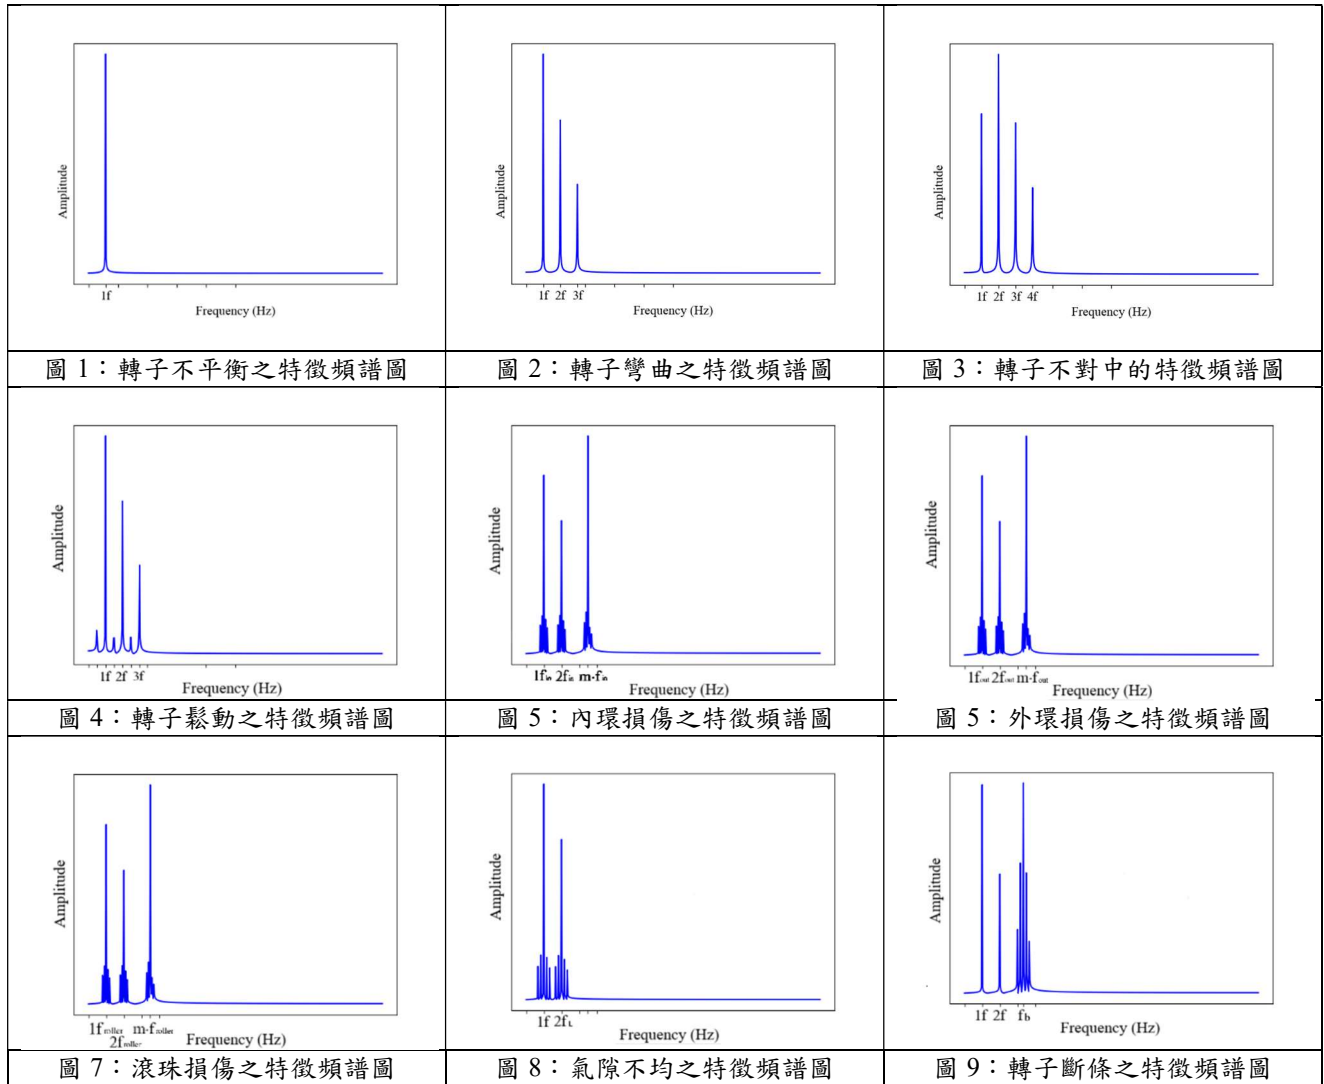
$$f_s = (N_s - N_r)/60 \quad (9)$$

其中， N_r 為轉子轉速、 N_s 為同步轉速如式(10)所示。

$$N_s = (120 \cdot f_L)/P \quad (10)$$

圖 9 為發生轉子斷條時所產生的特徵頻譜，其故障頻譜以 $1f$ 和 $2f$ 為主要特徵外，還出現以 f_b 為主頻並帶有頻距為 N_r 的伴頻。其中 f_b 為轉子通過頻率，可以式(11)來表示。

$$f_b = (B \cdot N_r)/60 \quad (11)$$



IV 情境設置與分析

4.1 硬體架構與馬達故障情境

本研究以工業界可程式邏輯控制器作為馬達運轉訊號的收集主機，將電力計、變頻器、振動規(TECOM VB-310 與 RTD 溫度感測(PT-100)等感測裝置裝設於馬達上，並將電壓、電流、馬達溫度、振動、轉速、負載量等相關判斷訊號透過 PLC 傳輸至 PC，再以 Python 程式進行狀態分析。圖 10 與圖 11 分別為本實驗之實驗架構設計圖與實體照片圖。此外，本研究的情境設定以正常馬達與故障馬達之偏軸(Rotor Unbalance)、轉子斷條(Rotor Bars Crack)、定子繞組短路(Stator Winding Short Circuit)等狀等項目進行規劃，用以了解各種故障所呈現的資訊。

4.2 數據資料收集

為進行馬達數據資料收集與故障分析，本研究將馬達運轉資訊透過 PLC 進行收集，包含電壓、電流、溫度與振動等資料。馬達框架上設置振動規取得運轉時的各項振動資料，各軸的位移、速度與加速度等，並將振動規時域訊號(rms)透過 RA2080-serialisol 的 Modbus 通訊模組(內含 RS485、RS232)將數據存入 PLC 的陣列中。本研究之感應馬達轉速為 1700 rpm，所以採計振動規之速度項即可，忽略位移與加速度。

特別說明，為了驗證本研究演算法的結果正確性，在振動數據分析方面，先將感測器所採集資料進行快速傅立葉轉換求得故障頻譜。由於原先的採樣頻率並不理想，無法配合奈奎斯特(Nyquist)頻率，至少須為基頻 30 Hz 的兩倍以上。為了後續的快速傅立葉轉換(FFT)，透

V 結果分析

過優化 Python 的讀取程式，增加採樣頻率使其符合上述所需之頻率。而為達成其目標，從降低 PLC 至資料庫的傳輸延遲開始著手，將一開始的隨傳即存，改為收集一定數量資料後才上傳至資料庫，搭配 Python 多緒 (Multithreading) 執行的功能擷取資料，採樣頻率提升了約 100 倍。最後，為進行馬達特徵頻譜分析，從資料庫下載資料送入 Python 進行正規化後運行 FFT 分析。圖 12 為本研究之馬達數據資料收集流程圖。

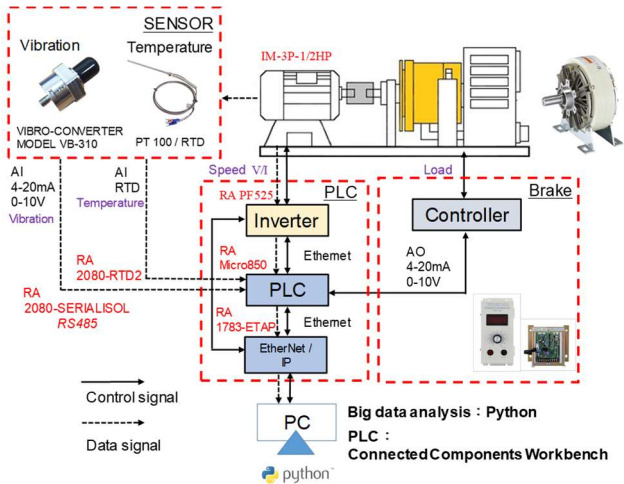


圖 10：實驗架構方塊圖




圖 11：實驗架構實體照片圖

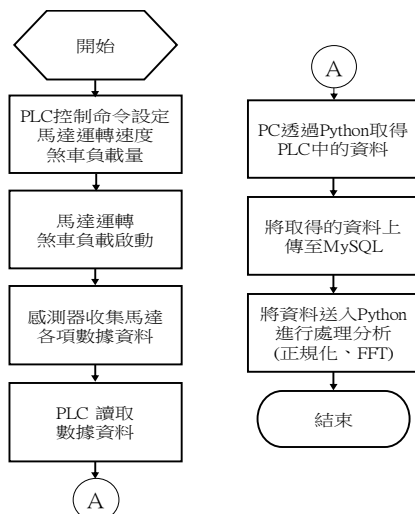


圖 12：馬達運轉數據資料收集流程圖

5.1 馬達故障檢出判斷與分析

本研究以正常馬達運轉與馬達偏軸、轉子斷條與定子繞組短路等項目進行測試，並以額定轉速 100% 驗證實驗架構、感測器資料收集與程式判斷之準確性。在設定情境下，為驗證感測器所收集資料是否正確，首先進行偏軸之故障分析與判定，將感測器所取得的資料進行傅立葉轉換後，可得到與上述文獻探討部分相符的結果，藉此驗證硬體架構的正確性。本量測結果顯示正常馬達之頻譜圖有三個較為凸出的頻率，分別約在 30、220 與 250 Hz。以馬達額定轉速為 1700 rpm，60 Hz 的電源下可推算頻率約在 28.3 Hz，由此驗證本實驗設定的準確性是可接受的，且符合馬達的實際情況。

上述正常與偏軸馬達的頻譜資訊是來自振動，但實際上，馬達故障訊息可能也會在電壓、電流與溫度上面來反應。因此，須依據硬體架構及感測器將大量收集的數據資料透過 PLC 傳送到 PC，再由程式進行故障判斷，作為本研究馬達故障分析資訊。本研究所收集資料特徵值高達 14 個項目，內含電壓、電流、溫度與振動，其中振動又含 X、Y、Z 三軸的速度、加速度、位移、峭度等資訊，資料量與特徵非常多且雜亂，因而不易判斷故障類別。在資料處理上先使用主成份分析法，利用資料在某一方向的投影量來壓縮，於提出特徵值時，也盡可能避免影響原始資料對整體群組的貢獻，進行二維化的同時能提供較佳的可視化效果。接著利用 K-近鄰演算法來分類故障資訊。

監督式學習法可明確判斷的資料為何種狀態，透過此演算法的密度特性，將資料密度權重過低的值予以濾除，進而提高模型的準確度。圖 14 為本研究之神經網路，X 為輸入層中有 14 項數據資料(電壓、電流、XYZ 軸速度、XYZ 軸加速度、XYZ 軸位移、XYZ 軸峭度、溫度)。隱藏層(第一層)中為主成份分析法(PCA)，將輸入的 14 項特徵值壓縮為 2 項特徵點；隱藏層(第二層)執行第一次 KNN，目的為將密度分數過低的樣本刪除，達到去雜訊的效果；隱藏層(第三層)做第二次 KNN，將去除雜訊後的資料再做一次分類，有效提高分類器的準確率，並刪除雜訊(第三層神經網路中又字記號之神經元)。最後輸出層分別產出正常馬達之 50%、100% 轉速、轉子不平衡、轉子斷條及繞組短路等五種故障判別結果。

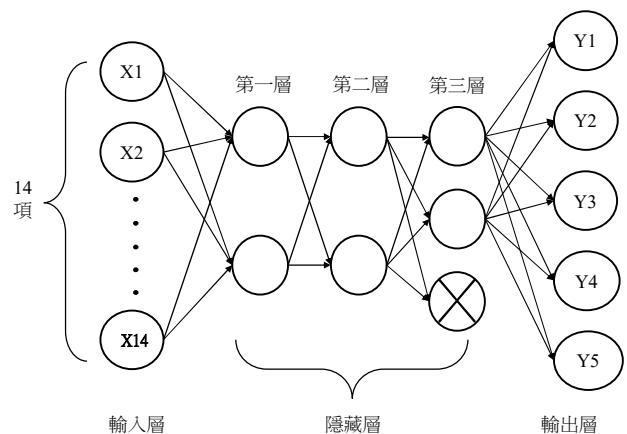


圖 14：馬達故障分析之神經網路示意圖

圖 15 為以 KNN 演算法將感測器所收集訊號資料進行運算，但並未經過雜訊處理的原始資料，其中深、淺水藍色點分別代表馬達正常轉速 50%與 100%之資料，紅色點為偏軸馬達之資料，綠色與紫色點分別代表轉子斷條與定子繞組故障分布。由圖 15 中可以看到，若僅執行 PCA 分類後，仍有些微的資料點(紅色)於外部區域，這會影響判斷結果。因此，需再以 KNN 將外圍密度相對較低的資料點設為雜訊，去除後可得結果如圖 16，去除圖 15 的誤差值後可獲得較佳的故障判別分類，也可清楚分辨出所設定的故障狀況。

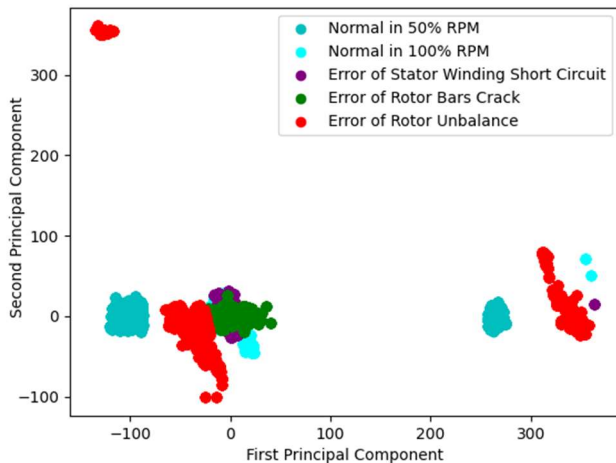


圖 15：五種馬達故障情境之訊號點分布圖
(原始之資料分布)




圖 16：五種馬達故障情境之訊號點分布圖
(去除雜訊後之資料分布)

V 結論

於為達成工業 4.0 的智慧檢測，本文以馬達常見的故障類別進行分析以及研究，歸納出每一種故障類別的特徵頻譜，並建立起故障頻譜的資料庫，再利用機器學習的方式使電腦能夠分辨故障種類並達到示警的功能。本研究為取得馬達之異常特徵透過 PLC 收集，包含電壓、電流、溫度與振動等資料。將資料統整過後送入程式內進行資料分析以及訓練，且為避免當發生複合型故障時，電腦無法準確判斷。於實驗時，故意使繞組短路與轉子斷條可同時存在，此時紫色點的繞組短路與綠色

點的斷條狀況在可視化作圖時是重疊的，但是在 KNN 的數值分析結果中是可清楚分辨的。透過這樣的方式，除了正常馬達、偏軸、轉子斷條與定子繞組短路等狀況外，若遇到其他複合型故障時，確保此程式可以正常運行並發揮功能。

致謝

本文承蒙科技部 109 年度一般研究計畫-基於大數據分析之遠洋漁船智慧負載管理平台的開發(MOST 109-2221-E-006-080-MY3)經費補助，特此感謝。

參考文獻

- [1] Ye Zhongming and Wu Bin, "A review on induction motor online fault diagnosis," Proceedings IPEMC 2000, Third International Power Electronics and Motion Control Conference, Vol.3, pp. 1353-1358, 2000.
- [2] 葛世偉、李明遠，"馬達軸承故障線上診斷技術研究"，工程科技與教育學刊，第 12 卷第 1 期，第 1-7 頁，2014 年。
- [3] 徐子權，"電氣與振動檢測法於馬達狀態評估之研究"，碩士論文，國立臺灣科技大學電機工程系，2014 年。
- [4] 江威增，感應馬達之故障分析及診斷系統，國立勤益科技大學，碩士論文，2014。
- [5] S. S. Dhamal and M. V. Bhatkar, "Modelling and Simulation of Three-Phase Induction Motor to Diagnose the Performance on Inter-Turn Short Circuit Fault in Stator Winding," 2018 International Conference on Computing, Power and Communication Technologies, pp. 1166-1172, 2018.
- [6] B. Mirafzal and N.A.O. Demerdash, "On innovative methods of induction motor inter-turn and broken-bar fault diagnostics," IEEE International Conference on Electric Machines and Drives, 2005.
- [7] Omar AlShorman, "A Review of Artificial Intelligence Methods for Condition Monitoring and Fault Diagnosis of Rolling Element Bearings for Induction Motor," Hindawi Shock and Vibration, Volume 2020.
- [8] [Date of retrieval: May. 21, 2021] <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html>.
- [9] [Date of retrieval: May. 21, 2021] <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>.
- [10] MySQL [Date of retrieval: Mar. 21, 2021] <https://www.mysql.com/>
- [11] 彭善謙，"綜合振動信號於馬達故障診斷"，碩士論文，中原大學機械工程學系，2004 年。
- [12] 趙安民，"馬達故障診斷之模糊類神經網路"，碩士論文，中原大學機械工程學系，2004 年。
- [13] M. Moghadasian, S. M. Shakouhi, and S. S. Moosavi, "Induction motor fault diagnosis using ANFIS based on vibration signal spectrum analysis," 3rd International Conference on Frontiers of Signal Processing (ICFSP), pp. 105-108, Paris, France, Sept. 6-8, 2017.