

電機工程學系一一〇學年度

『專題研究』期末報告

中文題目：兩階段深度學習

指導老師：王壘

專題組員：陳柏諺、楊孟軒

110 年 12 月 21 日

中文摘要

隨著工業機械能夠完成越來越複雜化、自動化的任務，這樣的發展意味著機械各部件得承受更為複雜的運作模式，也就是說，在該作業環境可能易遭受高溫高壓和高運轉量的困擾。因此，故障是不可避免的問題。由於機械設備故障容易導致經濟及能源消耗的損失，故機械狀態監控的需求變得日趨重要。

而大多數的機器錯誤檢測常須對一台機器做長久且專一的追蹤才能訓練出對應該台機器的錯誤檢測模型，雖然結果對當前環境精準但容易造成模型擬合過度(overfitting)，因此若過程中傳感器更換或位置偏移就可能造成整個模型失效，而造成訓練時間增加而難以快速大量部署。本研究提出利用多感測器配置來收集條件訊息的協同組合，從而做出最佳工具機檢測決策，利用多頭卷積架構通過將知識從一種模型轉移到另一種模型來生成新模型，由於彼此完全獨立，因此如果安裝或卸下更多傳感器也能及時快速部署。

關鍵字：異常檢測、坎入式系統、機器學習

目次

中文摘要	1
目次	3
第一章 緒論	4
1.1 前言	4
1.2 研究動機	4
1.3 研究方向	5
1.4 論文架構	6
第二章 背景介紹	7
2.1 Multi-head CNN-RNN [2]	7
2.2 Cross-machine fault diagnosis [3]	8
2.3 兩階段式異常檢測架構 [4]	9
第三章 系統理論與實作	10
3.1 整體系統架構	10
3.2 系統架構	10
3.3 資料傳輸	11
3.4 感應器選用	12
第四章 實驗與分析	14
4.1 實驗設備	14
4.2 研究方法及步驟	16
4.3 專題實際運作情況	17
第五章 結論	19
5.1 結論	19
5.2 未來展望	19

第一章 緒論

1.1 前言

工業界中使用智慧互聯是工業 4.0 智慧製造[1]的重要議題之一，然而當前的智慧工廠解決方案難以滿足多個設備間的智能交互、快速配置、線上服務等智能互聯，而且因成本受限與使用不易難以實際的大量部署，因此對目前國內僅有少數頭部企業有部署。

本專案首要目標是建立一個具有易用性可迭代升級與適合所有工具機部署的即時工具機雲端監控與維護之整合系統。進而提早發現機器異常並進行修復，提高工廠的生產效率與穩定性，降低因機器故障而造成工廠損失或是更嚴重的災難，並降低頻率太高的預防性更換造成的成本浪費行為，其中專案主要利用到的技術如下：

1. 深度學習與神經網路
2. 非監督式學習自動編碼器與轉碼器
3. 無線感測網路
4. 邊緣運算(edge computing)技術

1.2 研究動機

近年來雲端算與 AIoT 技術逐漸成為了趨勢，越來越多的企業開始加速了對於雲端的部署，更催化出了工業 4.0 的誕生，在工業 4.0 中，希望透過工業人工智慧的技術建立具有適應性、有效率的智慧型工廠，故障檢測技術在工業 4.0 中佔有龐大的應用價值。在工具機的異常檢測通常與機器維護同時並行，藉由感應器所蒐集到的資料在機器發生異常的早期提前發出警報，即時進行維修和保養。藉此降低維修成本與消除風險。

但是在實際作業環境中常因為空間與環境限制難以部署大量的有線傳感器，且多傳感器系統的異構時間序列數據和數據之間的交互關係仍舊是尚待解決的挑戰，固本專題計畫以無線傳感器與有線傳感器混合模式，結合基於異構數據型態轉換的深度學習模型，讓使用者可以依照現場環境快速有效的選擇傳感器並進行大量且高效的部署，再讓系統將感應器的數據集中到雲端進行運算，以對工具機做出高效的檢測。本專題有別於一般故障預測與健康管理(PHM)，要達到的目標為以下幾點：

1. 簡化系統架構，分為感應器端與系統端，降低系統維護與升級的困難度。
2. 解決模型容易對單一機器造成模型擬合過度(overfitting)的問題設計易於擴充部署的感應器系統。

1.3 研究方向

本計畫在達成目標過程將遭遇或需解決問題甚多，重點歸納如下述幾點：

1. 多傳感器系統的異構時間序列數據和數據之間的交互關係，統一並保留其特徵，來處理多傳感器系統的複雜順序，在考慮多數據間的關係，以對系統作出高效的檢測。
2. 利用多頭卷積架構通過將知識從一種模型轉移到另一種模型來生成新模型，由於彼此完全獨立，因此如果安裝或卸下更多傳感器也能及時快速部署。
3. 研究感應器無線網路設計與無線傳輸模組技術運用，並設計模組化的感應器與無線通訊網路，增加對於工具機檢測感應器分配及部署的自由度與準確度。

1.4 論文架構

本文架構第一章會介紹研究背景以及動機；第二章會介紹應用到的相關背景知識；第三章則是介紹本專題的實作方法；而第四章主要介紹整體系統，以及系統運作結果；第五章會對於本篇論文的總結。

第二章 背景介紹

2.1 Multi-head CNN–RNN [2]

這篇文章介紹了一種深度學習結構，此結構專門為多傳感器系統上的監督異常檢測而設計。此架構直接針對原始數據進行工作，因此無需進行預處理，也不需要其他領域知識。對於傳感器數據在多傳感器系統上可能具有不同的性質，此文章針對每個傳感器使用獨立的卷積頭，因此每個卷積模型可以適應每個傳感器的特徵。接著使用遞歸模型來統合所有卷積頭並診斷整個多傳感器系統。其提出的架構如圖 2-1

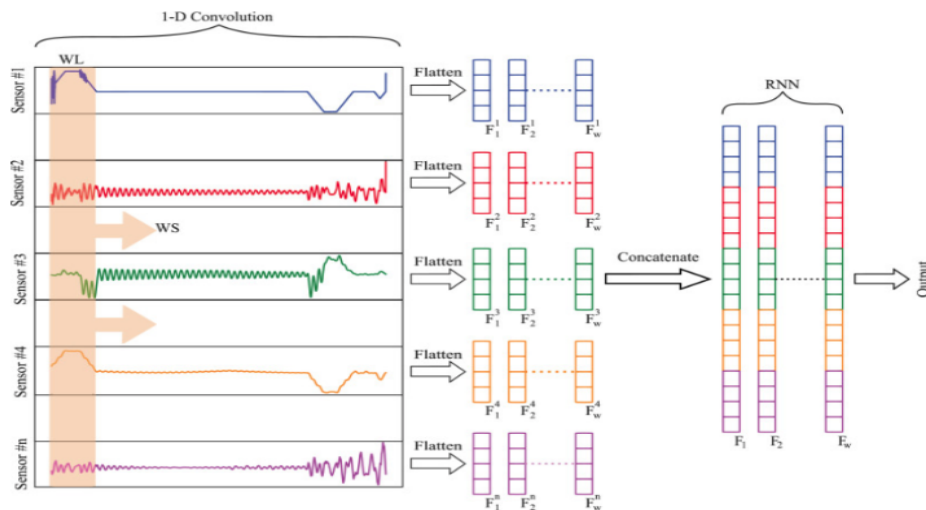


圖 2-1 (圖片引用自 [2])

除此之外，也為了傳感器配置的變化而需要生成新模型進行研究，利用多頭卷積架構通過將知識從一種模型轉移到另一種模型來生成新模型，由於卷積頭彼此完全獨立，因此如果安裝或卸下更多傳感器，可以輕鬆利用此架構添加或卸下卷積頭。

此論文的多頭式架構和利用轉移學習來生成新模型為本文提供了啟發，大量的傳感器應用必定是趨勢，但目前大多數的研究仍舊是僅針對同一種類

的傳感器數據進行分析，少有結合各種傳感器的檢測方法，此文的多頭架構正好有效的應對了這個問題，而此多頭的方法正好為利用轉移學習來生成新模型的方法，提供了有效的解決辦法，透過轉移學習的作法，在傳感器數量有變動時，就可以大大降低模型培訓的時間。但此論文較大的困難點是，現實的多傳感器系統是沒有標籤的，若要將此架構部屬於實際環境，將會很難來執行模型的培訓。

2.2 Cross-machine fault diagnosis [3]

此篇論文提出了將從一台機器學到的故障診斷知識，轉移到不同但相關的機器上的想法，該想法是通過基於深度學習的方法來實現的。首先使用自動編碼器結構，將不同設備的特徵投影到相同的子空間中，並採用跨機器自適應算法，進行知識概括，最小化來自不同計算機的數據之間的分配差異。其流程如圖 2-2 所示。

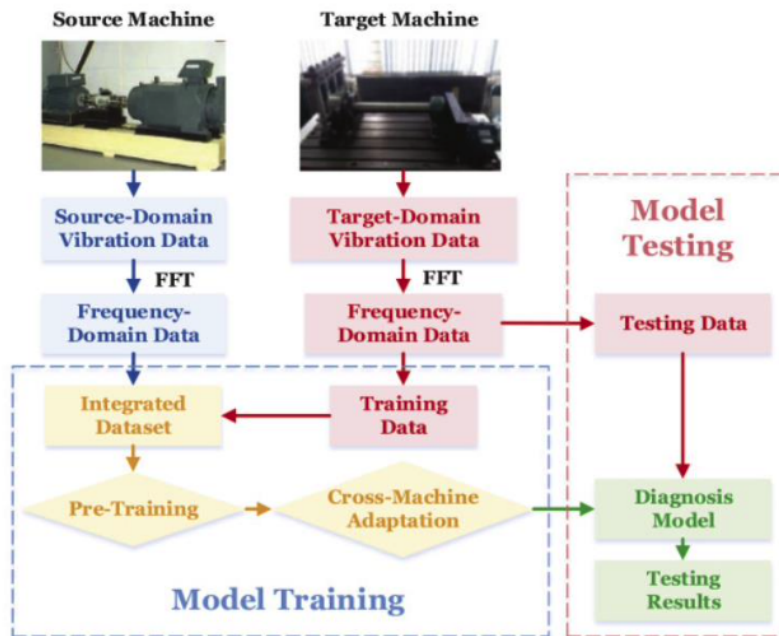


圖 2-2 (圖片引用自 [3])

此論文的方法有助於處理事先無法獲得標記的目標域數據，但先決條件是需要獲得目標域的監督資訊，而且用於轉移的數據之間必須是有關連的，

例如必需都是機械軸承的震動訊號，而且並沒有太大的容錯範圍，因此在實際的應用上還是會受到很大的限制。

2.3 兩階段式異常檢測架構 [4]

此篇研究是學長們所設計的兩階段式異常檢測架構此篇研究使用兩階段式異常檢測架構，其主要可分成三個部份，即系統管理(System Manager)、第一層(1st Layer)異質性(Heterogeneous)數據轉換層、第二層(2nd Layer) 齊次性(Homogeneous)數據交互關係層如圖 2-3。

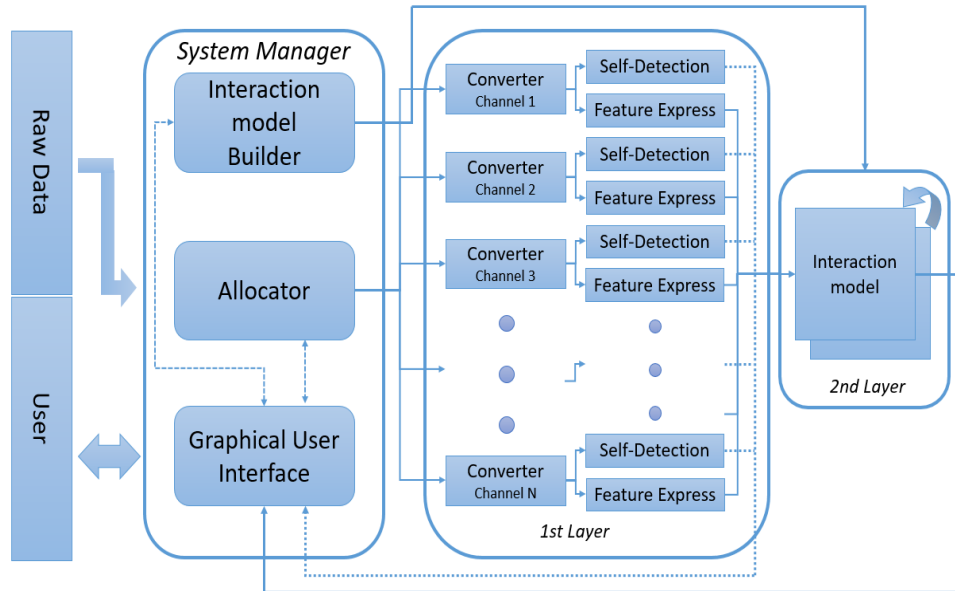


圖 2-3 (圖片引用自 [4])

此論文的方法可證明多階段的異常檢測是有用且高效的，並且因為 Converter 是一種無監督模型，其正規劃數據可有效反原先數據與目標數據的潛在分佈，因此可有效的解決多傳感器系統數據異構性導致的數據不平衡的問題，為多傳感器異常檢測系統提供了一個靈活的選擇。

第三章 系統理論與實作

3.1 整體系統架構

專題中使用多種不同的加速度感應器等感應器整合微控制器(MCU)裝置作為節點，再將數據彙整後以無線或是有線的方式傳入閘道器(Gateway)中，再藉由閘道器依據每個感應器數據進行第一階段(First Stage)的邊緣運算資料處理(Edge Computing)後將資料回傳給雲端伺服器進行運算，再將結果與系統狀態即時傳送給使用者。

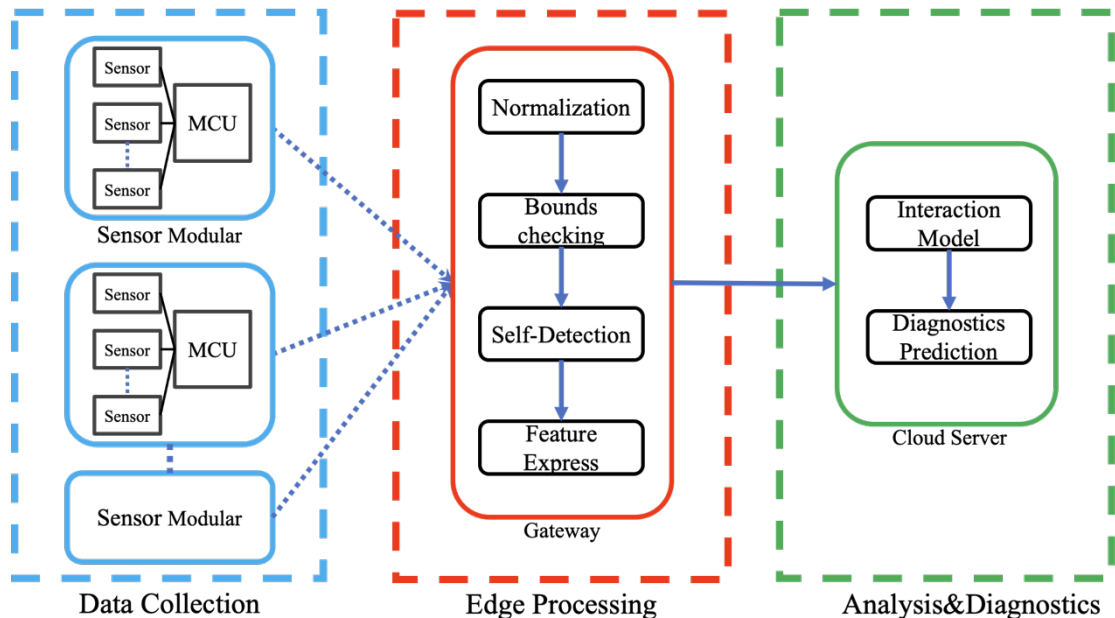


圖 3-1 系統架構簡圖

3.2 系統架構

其傳感器設備在設計時需考慮到實際情況，故本計劃提出使用模組化感應器網路方式，讓感應器終端可依照使用者要求更變其感應器數量、供電方式、通訊方式，其與閘道器(Gateway)通訊可依照環境與數據量來決定使用 BLE、WiFi 又或者有線傳輸等方式與閘道器進行溝通。

3.3 資料傳輸

本專題中採用以 TCP/IP 協議的 Socket 封裝通訊，Socket 本身是一個通訊方式，在嵌入式平台與主機之間使用 Socket 連線，可以快速的傳輸資料以及不會有缺失封包的問題。

Socket 使用方式只需要知道主機端的 IP 位置(IP number)與可運用的 port 腳，即可進行連線，最終達到本專題感測器資料的傳輸。

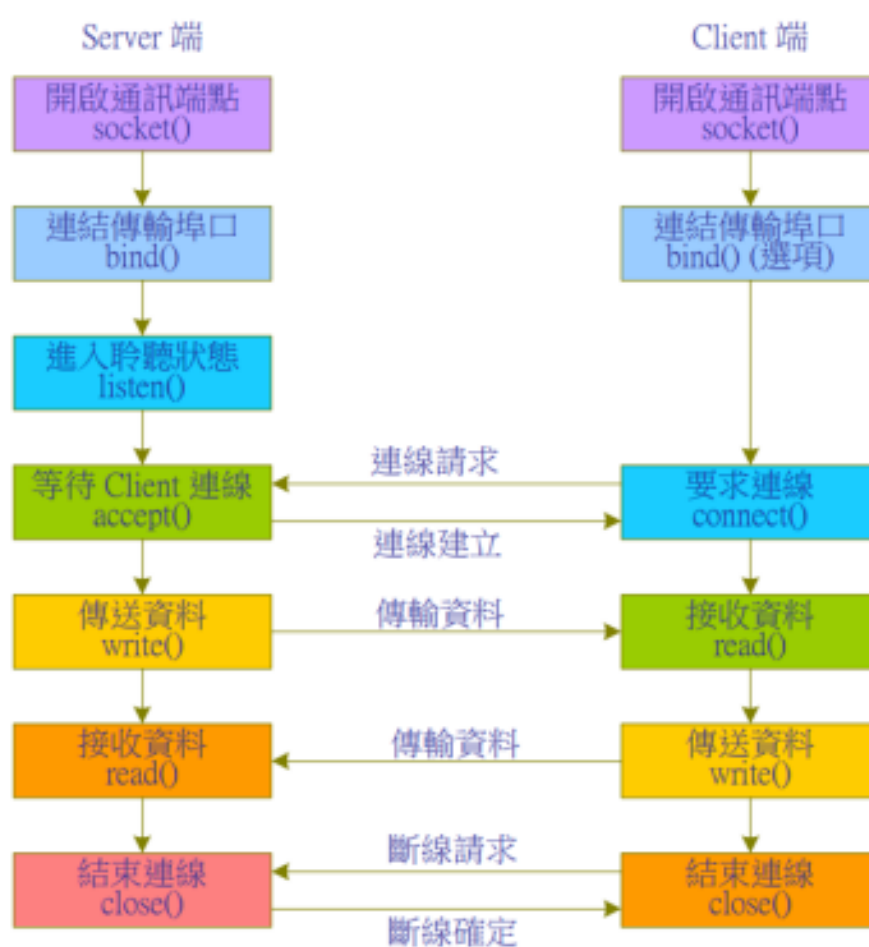


圖 3-2 Socket 通訊概念

3.4 感應器選用

研究中運用了多種不同的感應器架構，針對不同的機械，找出最適合的感測器搭配嵌入式裝置，才能蒐集到有用的機器數據。

MPU9250 9 軸傳動態傳感器

九軸運動跟踪感應模組(下圖)裝置運轉時所帶動的機械本體，可以知道機械動作是規律性的運動，以及擺動的範圍和方向隨著馬達運轉持續地規律變化，因此預蒐集機器運轉資訊，可透過三軸加速度進行採集。



圖 3-3 MPU9250 感應器

IIS3DWB 工業用 3 軸加速度傳感器

IIS3DWB 採用系統級封裝，配備了具有低噪音以及超寬且平坦頻率範圍的三軸數字振動傳感器。該器件具有高帶寬、低噪音、高穩定性和可重複靈敏度，以及在擴展溫度範圍可確保在更大的溫度範圍（-40 °C 至+105 °C）的工作能力，特別適合工業應用中的振動監控。低功耗、高性能、還有數字輸出和嵌入式數字功能（如 FIFO 和中斷），這些特點非常適合電池供電的工業無線傳感器節點。




圖 3-4 IIS3DWB 感應器

IIS3DWB 具有可選的滿量程加速度範圍 ($\pm 2/\pm 4/\pm 8/\pm 16\text{ g}$)，並且能夠測量帶寬最高達 6 kHz 的加速度項目，輸出數據率為 26.7 kHz。器件中集成了 3 kB 的先進先出 (FIFO) 緩衝器，以避免任何數據丟失，並限制主機處理器的干預。

意法半導體的 MEMS 傳感器模塊系列具有穩健成熟的製造工藝，已經用於微機械加工的加速度計和陀螺儀產品，服務於汽車、工業和消費市場。

第四章 實驗與分析

4.1 實驗設備

實驗中運用撞針機模擬真實工作環境進行驗證，因此我們運用此馬達運轉裝置(如下圖)來蒐集數據，此馬達運轉裝置主要為使用直流減速馬達連接一可旋轉金屬臂，藉由直流減速馬達旋轉帶動金屬臂運作以模擬應用於工業生產的機械裝置。




圖 4-1 測試平台

此實驗在裝置上配置了傳感器用以監測機械裝置的運行狀態以驗證藉由不同種類數據的整合分析，並將數據儲存進行預訓練與特徵提取。

在取樣馬達運作樣本部分，我們將模擬馬達正常運作與施加劇烈外力使之停擺運作，將其震動數據取樣成時域特徵(time domain features)，其特徵包括但不限於：1. Root Mean Square 2. Variance 3. Kurtosis 4. Peak Value 5. Skewness 6. Median 與其他特徵，其算法如下所示。

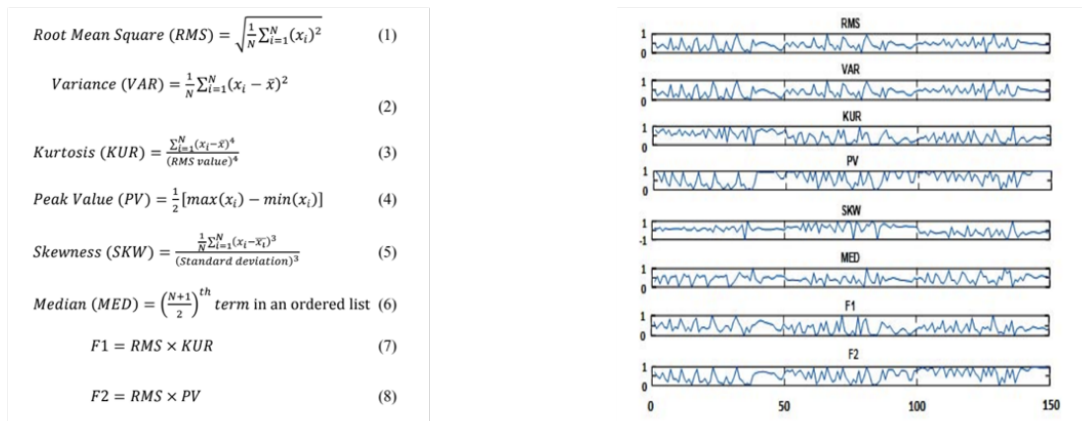


圖 4-2 time domain features

在訓練模型時我們採用 PCA 主成份分析對資料進行壓縮，並隨機取樣標籤過後的狀態資料進行第一階段的處理，隨機採樣 75% 的資料當成訓練集再用 KNN 製作分類器，並利用剩下的 25% 驗證，在驗證中模型可對運作狀態達成 90% 以上的分辨度。

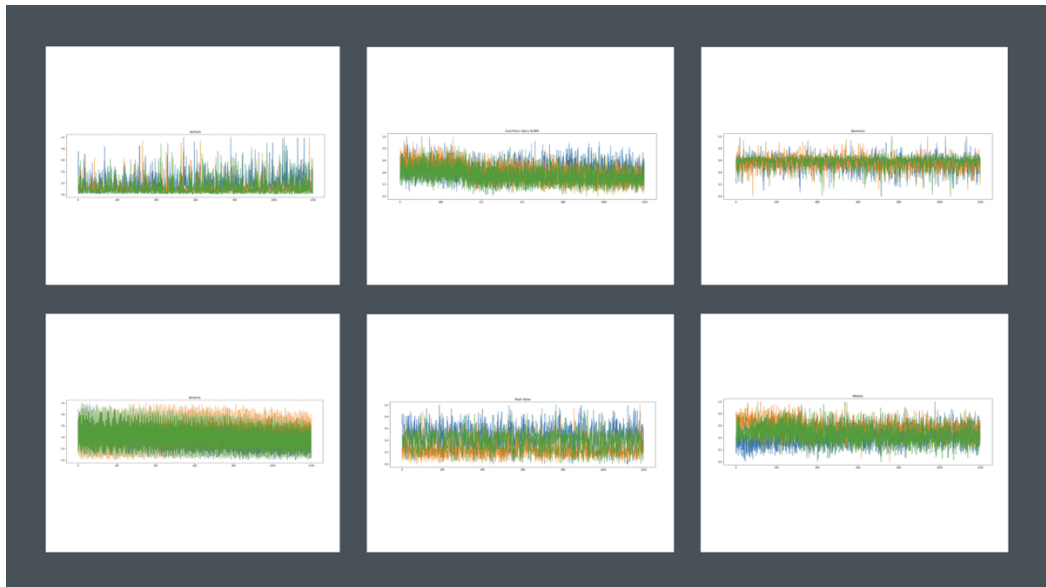


圖 4-3 實際轉換數據

4.2 研究方法及步驟

A. 資料分析與蒐集與提取

實驗中需使用大量的數據進行訓練與測試，故使用現有的、經過校正的機器運行狀況的辛辛那提大學智能維護中心的公開 IMS 軸承數據[]為主要資料集，再加上利用現有機台實際蒐集的撞針機與其他工具機數據，讓資料集中包含正常狀態至損壞的過程以及多種不同的軸承損壞狀況的數據，運用這些數據來評估模型對不同異常狀況的檢測能力以及訓練檢測模型。

B. 模型設計與訓練

運用收集來的數據，建立深度的神經網路模型，並分析哪種神經網路模型比較適合研究所期望的狀況，本研究根據 []的文章分析及判斷後，決定進行時間序列特徵的運算[]，較可能達成本實驗預期之數據轉換效果。且因為來自不同通道的數據會包含有不同的特徵，因此針對多通道數據的不同通道分別建立模型，會相比一個模型處理多通道要來的更加有效率，因此本研究選擇對不同通道建立不同的神經網路模型，使模型同時有能力進行異常狀態檢測。

最後，優化以及調整神經網路模型之架構，將網路上公開數據集拿進本研究建立之神經網路模型進行驗證，驗證模型建立是否為本實驗所預期之結果，並判斷是否需要對模型進行修正以及優化，找到效能最佳的組合。

C. 搭建模組化感應器網路

企劃中預計使用溫度、氣壓、加速度感應器等感應器整合微控制器(MCU)裝置作為節點，再將數據彙整後以無線或是有線的方式傳入閘道器(Gateway)中，再藉由閘道器依據每個感應器進行第一階段的邊緣運算資料處理(Edge Computing)後將資料回傳給雲端伺服器進行運算，再將結果與系統狀態即時傳送給使用者。

其傳感器設備在設計時需考慮到實際情況，故本計劃提出使用模組化感應器網路方式，讓感應器終端可依照使用者要求更變其感應器數量、供電方式、通訊方式，其與閘道器(Gateway)通訊可依照環境與數據量來決定使用 BLE、WiFi 又或者有線傳輸等方式與閘道器進行溝通。

4.3 專題實際運作情況

將模型訓練好後我們將模型部署在 NVIDIA Jetson 中將此設備做為網關與邊緣運算設備，並利用嵌入式系統(STM32&Espressif32)透過無線傳輸的方式傳送到網關中進行即時工具機監控系統簡圖如下圖 4-4 所示。




圖 4-4 工具機監控系統

系統可以藉由原先訓練好的工具機檢測模型對 MCU 中傳來的資料進行分類與檢測，其分類效果如下圖 4-5 所示，為了方便顯示系統將原先 3*8 維

度的數據運用 PCA(Principal components analysis)，將特徵壓縮成三維影像方便使用者觀看，同時系統狀態也可利用 GUI 即時顯示工具機運作狀態。




圖 4-5 壓縮後的特徵分類圖

第五章 結論

5.1 結論

本專題利用兩階段異常建測架構，搭配坎入式系統、無線通訊、機器學習與邊緣計算，製作工具機檢測系統，系統中的每個部分將來都可獨自的進行升級換代，使系統更新迭代簡單，將來若工具機部署需求擴大不需要將整套系統全部更換。

本專題中將此系統實際部屬在撞針機上，以檢測此異常檢測系統是否正常運作，並設立工具機的故障指標，經實驗證實，我們的機器可以準確地得知機器預發生異常的時間點，並提出異常警報，方便使用者檢閱。利用邊緣運算的方式降低部署成本，同時邊緣運算設備也做為多節點的閘道器，達到延遲與低成本的工具機檢測部署，大大的保障工廠機械的高效率運行。

5.2 未來展望

系統還有許多需要改進強化的地方，希望未來可以增加異音分析功能，因為在工具機運行時工具機的運作聲音也是非常重要的判斷基礎，異音分析技術我們希望採用麥克風陣列，結合卷積神經網路將蒐集到的環境聲音與工具機運作聲音分離，得到乾淨的工具機運作聲音後將數據利用邊緣運算設備整合進兩階段式 AI 異常檢測模型中，藉由原先訓練好的模型將聲音數據與傳感器數據進行整合。

參考文獻

- [1] Yan J., Meng Y., Lu L., Li L., “Industrial big data in an industry 4.0 environment: challenges, schemes, and applications for predictive maintenance,” IEEE Access, 5 (2017), pp. 23484-23491
- [2] MikelCanizo, IsaacTriguero, AngelConde, EnriqueOnieva, “Multi- head CNN–RNN for multi-time series anomaly detection: An industrial case study”, Neurocomputing, Volume 363, 21 October 2019, Pages 246- 260
- [3] P. Gołuch, J. Kuchmister, K. Ćmielewski, H. Bryś, “Multi-sensors measuring system for geodetic monitoring of elevator guide rails,” Measurement, 130 (2018), pp. 18-31
- [4] 林建宏, “齊次性輸入的數據整合故障預測方法”,逢甲大學碩士論文
- [5] Min Huang, ZhenLiu, YangTaob, “Mechanical fault diagnosis and prediction in IoT based on multi-source sensing data fusion,” Simulation Modelling Practice and Theory Available online 3 September 2019, 101981